Università degli Studi di Salerno

Corso di Fondamenti di Visione Artificiale e Biometria
2025/2026

Missing Data Imputation in Tabular Data

Diffusion LLMs

Tutor: Lucia Cascone lcascone@unisa.it
Tutor: Valeria Fraenza vfraenza@unisa.it

Missing Data

MCAR (Missing Completely At Random)
I dati mancanti sono completamente casuali, indipendenti da qualsiasi variabile:
- errori di misurazione/trascrizione
- perdita di dati

MAR (Missing at Random)
I dati mancanti dipendono da altre variabili osservate:
- valori mancanti legati alla popolazione in esame (età, genere, etnia)

MNAR (Missing Not At Random)
I dati mancanti dipendono dal valore stesso che manca:
- dati non forniti per privacy

Missing Data Imputation Strategies

METODI STATISTICI
Media
Mediana
MICE

METODI DI ML
Random Forest
Gradient Boosting
Regressione
KNN

METODI GENERATIVI
Generative Adversarial Networks
Variational Autoencoder
Tabular Variational Autoencoder

METODI DI LINGUAGGIO
Large Language Models
Diffusion Language Models

Diffusion Language Models

Gli **LLM (AR-models)** producono testo <u>token per token</u> in sequenza.

I **DLM** generano intere sequenze in <u>modo iterativo</u> tramite la <u>riduzione del rumore.</u>

- contesto bidirezionale
- generazione parallela
- maggiore rapidità

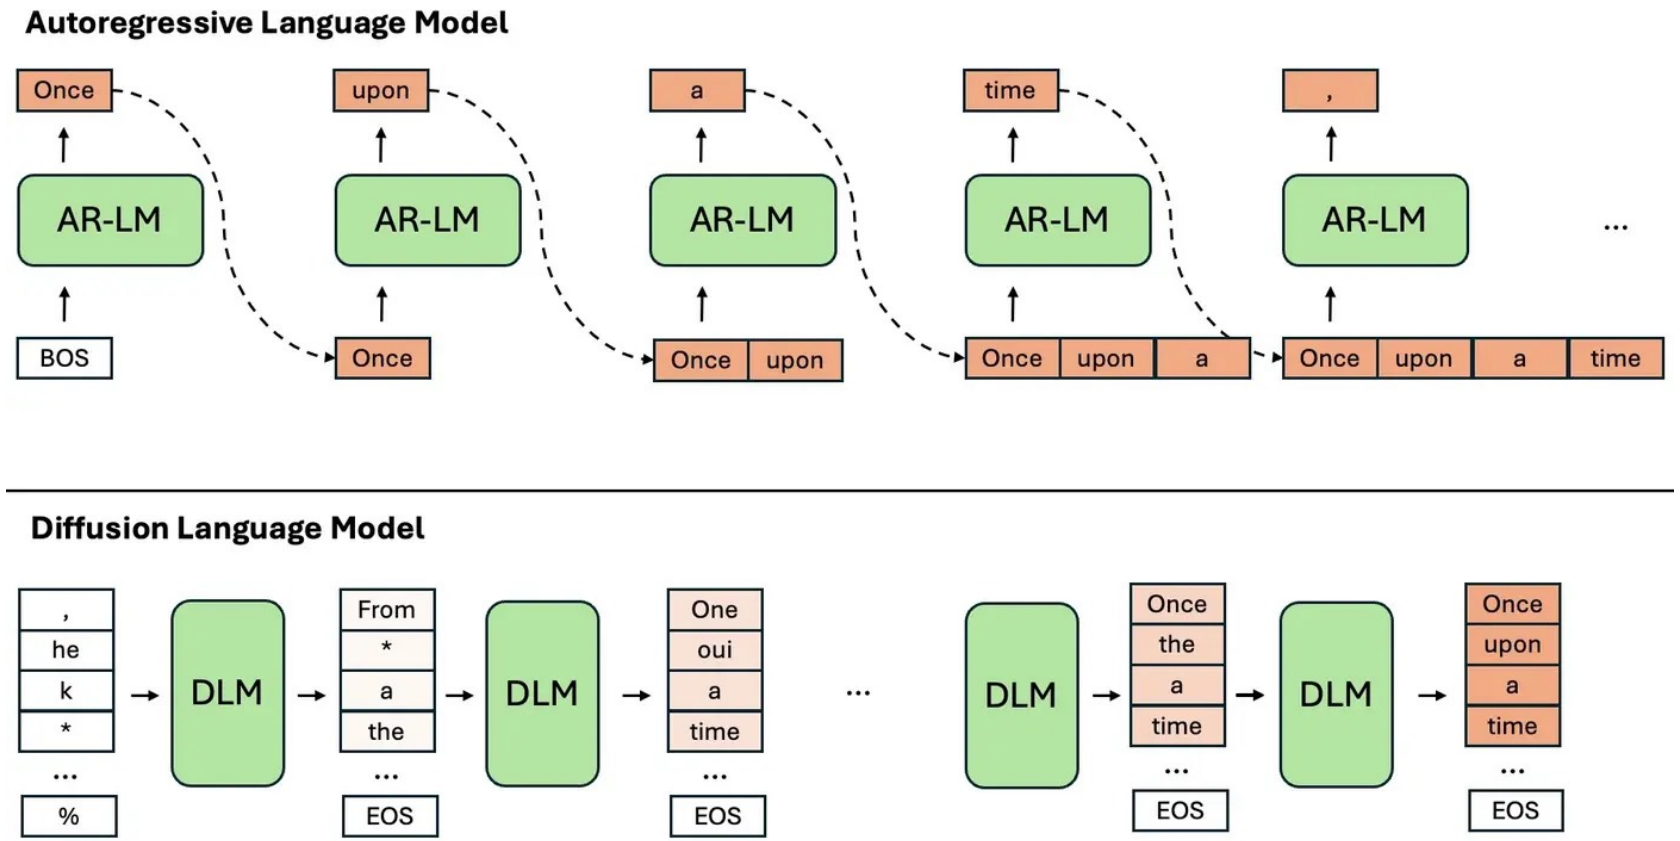

https://spacehunterinf.github.io/blog/2025/diffusion-language-models/

Obiettivo

Analizzare l'impatto e l'efficacia dei Diffusion Language Models nel task selezionato.

Confrontare le prestazioni dei Diffusion Language Models rispetto alle diverse tecniche di imputazione.

Valutare robustezza e generalizzazione dei Diffusioni Language Models usando più dataset di benchmark.

Usare il seguente lavoro come riferimento:

Villaizán-Vallelado, M., Salvatori, M., Segura, C., e Arapakis, I. (2025). *Diffusion Models for Tabular Data Imputation and Synthetic Data Generation*. ACM Transactions on Knowledge Discovery from Data, 19(6). Association for Computing Machinery, New York, NY, USA. Disponibile al link: https://doi.org/10.1145/3742435.

Dataset

Home Equity Line of Credit (HELOC) - classificazione binaria
Riguarda le richieste di linee di credito HELOC.
Predizione se il richiedente effettuerà pagamenti puntuali in un periodo di due anni.

Churn Modelling - classificazione binaria
Riguarda clienti bancari.
Predizione se il cliente ha chiuso o meno il proprio conto.

California Housing - regressione
Riguarda abitazioni situate in un determinato distretto della California.
Previsione del prezzo di un immobile.

House Sales King Country - regressione
Riguarda abitazioni nella regione della contea di King.
Stima dei prezzi degli immobili venduti tra maggio 2014 e maggio 2015.

Workflow

Fase 1: Studio dettagliato della letteratura sui DLM

Fase 2: Replicare protocollo sperimentale

Fase 3: Imputazione con LLMs

Fase 4: Imputazione con DLM

Fase 5: Analisi performance
- prestazioni predittive
- efficienza computazionale

Models and Limitations

Mercury

- API pubblica con restrizioni
  (Numero massimo totale di tokens e numero massimo per minuto di tokens)
- chat.inceptionlabs.ai
- Paper link: https://doi.org/10.48550/arXiv.2506.17298

Dream7B

- Open source - Huggingface hub
- Paper link: https://doi.org/10.48550/arXiv.2508.15487

LLaDa-8B

- Open source - Huggingface hub
- Paper link: https://doi.org/10.48550/arXiv.2502.09992

Materiale da produrre

- Archivio contente il codice prodotto (.py o .ipynb) opportunamente commentato e corredato di tutti i files utili all'esecuzione

- Short-paper strutturato come di seguito:

1. Abstract
2. Introduzione e descrizione del problema
3. Stato dell'arte/Related Works
4. Sistema proposto (sezione in cui esporre la strategia implementativa adottata)
5. Risultati sperimentali (sezione in cui vengono presentati i risultati raggiunti in termini di metriche come accuracy, F1-score, MSE etc..)
6. Discussione dei risultati (sezione in cui discutere e analizzare i risultati ottenuti)
7. Conclusioni

- Presentazione finale

Stato dell’Arte

Surveys sui diffusion language models

Tseng, C.Y., Zhang, D., Bi, Z., e Song, J. (2025). *Diffusion-based Large Language Models Survey*. TechRxiv. https://doi.org/10.36227/techrxiv.175502932.20939890/v2.

Li, T., Chen, M., Guo, B., e Shen, Z. (2025). *A Survey on Diffusion Language Models*. arXiv. https://doi.org/10.48550/arXiv.2508.10875.

Università degli Studi di Salerno

Corso di Fondamenti di Visione Artificiale e Biometria
2025/2026

Missing Data Imputation in Tabular Data

Diffusion LLMs

Tutor: Lucia Cascone lcascone@unisa.it
Tutor: Valeria Fraenza vfraenza@unisa.it